

Прогнозирование спроса на такси

Краткий MLOps-проект: предсказываем количество заказов по часовым временным рядам, чтобы оптимизировать распределение парка и снизить время ожидания пассажиров.

АВТОР: ДРОБКОВ БОГДАН

СТЕК: PYTHON · SCIKIT-LEARN · CATBOOST · MLFLOW · DOCKER



Бизнес-задача

Цель

Прогнозировать количество заказов такси на следующий час с достаточной точностью для принятия операционных решений.


Ценность для бизнеса

- Оптимизация распределения машин в городе
- Снижение времени ожидания клиентов
- Уменьшение простаивания водителей
- Увеличение выручки и улучшение SLA

Данные и признаки (ETL)

Источник: исторические логи заказов (taxi.csv). Обработка и признаки проектируются так, чтобы модель понимала временную структуру и сезонность.

1. Преобразование datetime, установка времени как индекса
2. Ресемплирование по 1 часу, заполнение пропусков
3. Feature engineering: hour, dayofweek, month, праздничные метки
4. Лаг-признаки и rolling mean для захвата автокорреляции



Архитектура ML-системы



Data

Хранилище сырых логов → регулярный инкрементальный импорт.



Train & Evaluate

src/train.py / src/evaluate.py, MLflow для трекинга экспериментов.



Preprocess

src/preprocess.py: очистка, трансформации времени, ресемплинг.



Deploy

Docker-контейнеры, CI (GitHub Actions), эндпоинт для прогнозов и мониторинг качества.



Feature Engineering

lag, rolling, календарные признаки, внешние факторы (погода, события).

Схема Пайплайна проекта

Raw Data - Preprocessing - Feature Engineering - Train/Test Split - Model Training - Hyperparameter Tuning - Model Evaluation - MLflow Logging - Model Saving - Testing & CI/CD - Docker Container

Модели и автоматизация

Набор моделей выбран с прицелом на скорость, интерпретируемость и устойчивость к сезонности.

- Linear Regression — простая и быстрая в продакшне
- Random Forest — нечувствителен к нелинейностям
- CatBoost — хорошо работает с временными рядами

AutoML-подход: перебор моделей, GridSearchCV для гиперпараметров, выбор по RMSE, трекинг в MLflow.

Результаты и метрики

Основная метрика — RMSE :

Linear Regression

RMSE: 34.47 — лучшая модель по простоте и стабильности.


Random Forest

RMSE: 42.09 — более вариативна, медленнее в inference.

CatBoost

RMSE: 40.19 — хорошая точность, но сложнее в деплое и мониторинге.

Результаты лучшей модели :



Выводы и рекомендации для бизнеса

- Модель успешно прогнозирует часовой спрос; точности достаточно для планирования выделения машин.
- Linear Regression – выбранная модель: проста, стабильна, легко объяснима.
- Дальнейшие улучшения: ввод внешних признаков (погода, события), онлайнное обновление модели, A/B тестирование расписаний.



Бизнес-эффект: снижение простоев, улучшение времени ответа и рост дохода при сохранении простой поддержки и объяснимости модели.